

2026-2 AI SOTA Paper Review Study

DOES ON-POLICY DISTILLATION REALLY DISTILL? FROM NOISY TEACHER TO SELF-IMPROVEMENT

교사 모델은 필요 없다: OPD의 역설과 엔트로피 기반 자가 학습(OPSA)
| RL의 기초부터 OPSA의 탄생까지..



Contents

컨텐츠 목차

1 강화학습(RL) 기초 및 LLM Alignment 트렌드

2 Base 논문: On-Policy Distillation (OPD)의 핵심


3 본 논문의 충격적 발견: 교사 신호의 노이즈와 역설

4 제안 방법론: On-Policy Self-Adaptation (OPSA)

5 실험 결과 및 소거 연구 (Ablation Studies)

6 PyTorch 핵심 코드 구현 및 최종 토론

1-1. 강화학습(RL)이 뭔데?



1-2. Policy Gradient 수식 이해

$$\nabla_{\theta} \mathcal{L} = -A_i \cdot \nabla_{\theta} \log \pi_{\theta}(y_i \mid x, y_{<i})$$



A_i : 현재 행동이 평균적인 기대치보다 얼마나 더 좋은가/나쁜가를 나타내는 수치

$A_i > 0$ (양수 보상): “잘했다” → 해당 토큰의 생성 확률 $\pi_{\theta}(y_i)$ 을 높임

$A_i < 0$ (음수 보상): “못했다” → 해당 토큰의 생성 확률 $\pi_{\theta}(y_i)$ 을 억제함

1-3. LLM Reinforcement Learning 발전 흐름

2022년


2023년

2024년

2025년~현재

RLHF(PPO)

- Reinforcement Learning from Human Feedback
- SFT(Supervised Fine-Tuning)
- Human Preference
- 말 잘 듣는 AI(Safety/Helpful)





DPO

- Offline Preference Optimization
- Preference Dataset
- 학습 효율성 & 비용 절감

GRPO / RLAIIF

- GRPO: group 내에서의 상대평가
- RLAIIF: RL from AI feedback
- AI Model / Rule-based
- RL 루프 가벼움화



RLAIIF에서의 Reward Hcking 문제 다룬 논문(commit-first 방식 제시)


RLVR (o1, R1) / OPD

- Reinforcement Learning with Verifiable Rewards
- On-Policy-Distillation
- Verifiable Outcome / Token Dense Signal
- 생각하는 AI (Lone-horizon Reasoning)

2-1. 토큰 단위 Dense Reward의 필요성

Sparse Reward(문장 끝 1개 보상) vs Dense Reward(토큰마다 보상)

Trajectory-Wise Sparse Reward




(a) Existing Approaches (e.g., Flow-GRPO)

Outcome-based Sparse Reward

어디서 틀렸는지 세밀한 전달 불가
→ 학습 효율 저하 & High Variance 문제!

Step-Wise Dense Reward



(b) DenseGRPO


Token-level Dense Signal

매 토큰 단위마다 Advantage 신호 전달

2-2. OPD(On-Policy Distillation)란 무엇인가?

On-Policy Rollout

- Teacher 모델의 답
안지 따라 읽기 X
- 틀리더라도 끝까지
Sampling 해보기



토큰 단위 피드백

학생 모델은 생성한 각
토큰이 얼마나 타당한지
채점받음
→ 가중치 업데이트

논문출처

https://proceedings.iclr.cc/paper_files/paper/2024/hash/5be69a584901a26c521c2b51e40a4c20-Abstract-Conference.html

2-3. OPD의 수학적 정의 (Reverse KL Divergence)

1. 목적 함수 (Objective Function): Reverse KL Divergence

$$\mathcal{L}_{\text{OPD}}(\theta) = \mathbb{E}_{y \sim \pi_{\theta}(\cdot|x)} [D_{\text{KL}}(\pi_{\theta}(\cdot|x, y_{<i}) \parallel \pi_t(\cdot|x, y_{<i}))]$$

2. 수식 분해 및 그래디언트(Gradient) 도출

$$\nabla_{\theta} \mathcal{L}_{\text{OPD}}(\theta) = \mathbb{E}_{y \sim \pi_{\theta}} \left[\underbrace{\sum_{i=1}^T \nabla_{\theta} \log \pi_{\theta}(y_i|x, y_{<i})}_{\text{학생의 확률 조절}} \times \underbrace{A(x, y_{\leq i})}_{\text{어드밴티지 (Reward/Penalty)}} \right]$$

3. 어드밴티지 $A(x, y_{\leq i})$ 의 의미 해석

$$A(x, y_{\leq i}) = \log \pi_t(y_i|x, y_{<i}) - \log \pi_{\theta}(y_i|x, y_{<i})$$

2.4 기존 학계가 가졌던 OPD의 근본적 믿음

📌 기존 통념

"더 거대한 교사 모델(예: 235B)이 학생(1.7B)에게 정교하고 지혜로운 '지식 전달(Knowledge Transfer)'을 해 줄 것이다."

😊 기대 효과

학생은 교사의 모범 답안 분포를 모방하며 빠르게 추론 능력을 습득할 것이다!

(실제로 효과가 있는 것처럼 보이긴 했습니다만...)

takes my eyes off of my class for 1.7 seconds

My students:



3-1. 본 논문의 핵심 질문 (Core Question)

교사 모델은 과연 학생이 작성한
오프폴리시(Off-policy) 문맥에서도
신뢰할 수 있는 지도 신호를 제공하는가?



- 학생이 푼 풀이과정($y_{\{i\}}$)은 교사 모델이 직접 쓴 글이 아님.
- 낯선 문맥을 마주한 교사 모델이 과연 제대로 된 점수를 줄 수 있을까?

3-2. 충격적 발견 1 - 교사의 피드백은 극심한 노이즈 투성이다

1 4B 교사: 30.6% 노이즈


2 30B 교사: 34.7% 노이즈

3 235B 교사: 50.6% 노이즈 (동전 던지기 수준)


노이즈 정의

| 교사 모델의 피드백 신호와 실제 최종 정답의 정확도(Ground Truth Correctness)가 충돌하는 경우

- False Negative (억울한 감점): 학생이 최종적으로 정답을 맞힌 트래젝터리(풀이 과정)임에도 불구하고, 교사가 해당 토큰에 음수의 어드밴티지($A_i < 0$)를 주는 경우
- False Positive (잘못된 칭찬): 학생이 최종적으로 오답을 냈음에도 불구하고, 교사가 그 오답으로 가는 토큰들에 양수의 어드밴티지($A_i > 0$)를 주는 경우



(a) Reward-advantage direction mismatch




(b) Training dynamics under different supervision

3-3. 충격적 발견 1 - 정답을 맞춰도 감점을 때리는 235B 교사


학생 모델이 최종 정답 \boxed{} 토큰을 맞췄을 때의 교사 어드밴티지 분석

→ Qwen3-235B 교사의 행동

학생이 정답을 맞혔음에도 불구하고 \boxed{} 토큰의 97.8%에
음수 어드밴티지(벌점)를 부여



(a) Reward-advantage direction mismatch



(b) Training dynamics under different supervision

3-4. 분포 불일치(Distributional Mismatch) 현상

WHY?

원인: 분포 불일치(Distributional Mismatch) 현상

1

표현 방식의 차이: 초대형 교사 모델(235B)은 소형 학생 모델(1.7B)과 문맥을 이해하고 문장을 생성하는 스타일/확률 분포의 차이가 매우 큼니다.

2

과도한 감점(Over-pessimism): 교사 모델의 규모가 커질수록 "자신이 선호하는 표현 방식"과 조금만 달라도 학생 모델이 생성한 모든 토큰에 음수의 어드밴티지($A_i < 0$)를 남발하는 경향이 강해집니다.

!

학생 모델이 정답을 맞혔음에도 교사 모델은 학생의 생소한 풀이 스타일을 틀린 것으로 간주하여 감점을 주는 비율이 폭증하게 됩니다.

3-5. 충격적 발견 2 - 노이즈 피드백만 모아 학습시켜도 똑같이 성장한다


1 Standard OPD: 기존 방식(노이즈 + 정제 신호 혼합)

2 Noisy only: 100% 노이즈 피드백


3 Clean only: 100% 올바른 피드백

!!!차이가 없음!!!

OPD에서 학생 모델이 성능이 오르는 이유가 "교사가 정답/오답을 잘 가르쳐줘서(Distillation)"
가 아니라는 것을 완벽하게 입증




(a) Reward-advantage direction mismatch



(b) Training dynamics under different supervision

3-6. 성능 향상의 진짜 원인 탐색 1 - 어디서 학습이 일어나는가?

$$\nabla_{\theta} \log \pi(y_i) = \frac{\nabla_{\theta} \pi(y_i)}{\pi(y_i)}$$


Head 토큰 (상위 80% 확률)

이미 확신하는 토큰은 분모가 크고 소프트맥스 특성상 기울기(Gradient)가 0으로 수렴




Tail 토큰 (하위 20% 확률)

확신 없이 불안정하게 출력된 토큰에서 그래디언트가 폭발

3.7 - 성능 향상의 진짜 원인 탐색 2 - 칭찬이 아니라 '벌점'이 동력이다

- 1 Positive-only ($A_i > 0$ 만 적용): 성능 향상 거의 없음
- 2 Negative-only ($A_i < 0$ 만 적용): Standard OPD와 동일한 성능 달성
- 3 Fixed Negative ($A_i = -0.5$ 고정): 하위 20% 토큰에 똑같이 -0.5만 줘도 OPD와 대등

OPD의 본질은 Tail 토큰을 억제하는 작업에 불과함



4-1. 제안 방법론: OPSA (On-Policy Self-Adaptation)

OPD

학생 모델이 토큰을 생성
→ 초대형 외부 교사 모델이 매 토큰마다 Advantage 계산
→ 노이즈가 섞인 피드백으로 학생 학습

OPSA

- 외부 교사 호출 X
- Ground Truth 필요 X
- Verifier 필요 X
- 자신의 토큰별 예측 확률 분포 및 엔트로피 정보만으로 자체적인 어드밴티지 신호를 즉석에서 구성하여 학습

Methods	Dense Signal	No Verifiable Reward	No External Teacher	No Hint
RLVR (Shao et al., 2024)	X	X	✓	✓
TTRL (Zuo et al., 2026)	X	✓	✓	✓
OPD (Lu & Lab, 2025)	✓	✓	X	✓
OPSD (Zhao et al., 2026)	✓	✓	✓	X
OPSA (Ours)	✓	✓	✓	✓

4-2. OPSA의 3단계 파이프라인

- 1단계 (Sampling): 학생 정책 π_s 로 문장 궤적 생성
- 2단계 (Filtering): $\log \pi_s$ 가 하위 20%에 속하는 Tail 토큰 집합 T_{tail} 추출
- 3단계 (Advantage Assignment): 선택된 Tail 토큰에 엔트로피 비례 동적 음수 어드밴티지 부여

4-3. 엔트로피(Entropy)의 수학적 의미와 계산

$$H_i = - \sum_{v \in V} \pi_s(v \mid x, y_{<i}) \log \pi_s(v \mid x, y_{<i})$$

- 엔트로피 = 예측 불확실성 (Uncertainty)의 크기
- 저엔트로피: 다음 단어가 명확함 (예: 단순 계산, 정형화된 문법)
- 고엔트로피: 여러 논리적 선택지 사이에서 고민 중 (예: "Therefore", "Wait", "However") → 분기점(Fork Tokens)

- H_i : i 번째 토큰 위치에서의 엔트로피(불확실성) 값
- V : 언어 모델이 가진 전체 단어장(Vocabulary) (예: 32,000개 ~ 128,000개의 토큰들)
- $v \in V$: 단어장에 존재하는 개별 단어/토큰 하나하나
- $x, y_{<i}$: 입력 프롬프트 x 와 $i-1$ 번째까지 이미 생성된 문맥(Context)
- $\pi_s(v \mid x, y_{<i})$: 현재 문맥이 주어졌을 때, 학생 모델이 다음 단어로 v 라는 특정 단어를 선택할 확률 ($0 \leq \pi \leq 1$)
- $-\log \pi_s(\dots)$: 확률의 로그값 (확률이 낮을수록 $-\log \pi$ 는 매우 큰 양수가 됨 → '정보량' 또는 '놀람의 정도')


4-4. 엔트로피(Entropy): 불확실성의 크기

저엔트로피 ($H_i \rightarrow 0$, 확신하는 상태)


- 정의: 특정 단어 하나에 확률이 쏠려 확률 분포가 뾰족한 상태
- 의미: 다음 나올 단어가 사실상 고정되어 고민 없이 확신하는 상태 (예: 단순 연산 결과, 정해진 문법 표현)

고엔트로피 ($H_i \gg 0$, 불확실한 상태 / 분기점)


- 정의: 여러 선택지에 확률이 골고루 분산되어 확률 분포가 평평한 상태
- 의미: 추론의 방향이 오답과 정답으로 갈라져 모델이 갈팡질팡하는 갈림길 상태 (예: "Wait...", "Therefore..." 등 논리 전환 시점)




(a) OPSA suppresses low-probability tail mass



(b) OPSA redistributes mass among head tokens



(c) OPSA avoids sampling low-confidence tokens



(d) OPBA maintains high-confidence tokens

4-5. OPSA의 동적 어드밴티지 수식


$$\tilde{H}_i = \frac{H_i - H_{\min}}{H_{\max} - H_{\min}} (\text{Min} - \text{Max 정규화})$$

- H_i : i 번째 토큰 지점에서 실제로 계산된 원래 엔트로피 값
- $H_{\min}, H_{\max}$: 해당 문장/배치(Batch) 내에서 나타난 엔트로피의 최솟값과 최댓값
- $\tilde{H}_i$: 0과 1 사이로 스케일링된 정규화 엔트로피 값 ($\tilde{H}_i \in [0, 1]$)
- 상대적인 불확실성의 크기를 [0(최저 불확실성), 1(최고 불확실성)] 표준 범위로 압축해 안정적인 학습 환경 구성


$$A_i^{\text{dyn}} = -0.5 - 0.5 \cdot \tilde{H}_i$$

- 정규화 엔트로피를 실제 음수 벌점 값으로 선형 변환
- $[-1.0, -0.5]$ 의 하한/상한 범위를 가짐
- 모든 Tail 토큰에 기본 감점(-0.5) 보장:
- 불확실한 분기점 추가 징벌 (가산 벌점 -0.5):
- 폭발 방지 (Gradient Clipping 효과)


4-6. 메커니즘 - 확률 질량 재분배 (Probability Mass Redistribution)




(a) OPSA suppresses low-probability tail mass



(b) OPSA redistributes mass among head tokens



(c) OPSA avoids sampling low-confidence tokens



(d) OPSA maintains high-confidence tokens

- 저엔트로피 위치: 약한 벌점(-0.5) → Top-1 토큰 확신도 유지
- 고엔트로피 분기점: 강한 벌점(-1.0) → 이상한 꼬리 토큰을 강하게 차단
- 핵심: 억제된 확률이 상위 유력 후보(Head) 단어들에게 골고루 재분배되면서 자발적 사고 탐색 가능

4-7. OPSA의 전체 Loss 함수

$$\mathcal{L}_{OPSA} = -\mathbb{E}_{y \sim \pi_s} \left[\frac{1}{|T_{tail}|} \sum_{i \in T_{tail}} A_i^{dyn} \log \pi_s(y_i \mid x, y_{<i}) \right]$$



상위 80% 토큰은 마스킹하여 Gradient 계산에서 완전히 배제

오직 하위 20% Tail 토큰에 대해서만 동적 음수 어드밴티지로 역전파 진행

5-1. 실험 설정 (Experimental Setup)

1

학습 모델: Qwen3 (1.7B, 4B) 및 Qwen3.5 (9B)

2

학습 데이터: DAPO-17k (정답 라벨/검증 없이 질문 데이터만 사용)

3

평가 데이터:

- 수학: AIME24, AIME25, HMMT25
- 기타(일반화): MBPP+ (코드), GPQA-Diamond (지식)

4

RLVR (GRPO), TTRL, OPD, OPSD

5

핵심 학습 조건:

- 하위 20% log-p 토큰만 선택해 학습
- 외부 교사 모델 및 정답 보상(Reward) 전혀 없음
(Zero External Supervision)

6

평가 방식: 문제당 32개 응답 생성 후 Avg@32 및 Pass@32 측정


5-2. 메인 결과 1 - 수학 추론 성능 완승

Methods	Math (I.D.)						O.O.D.	
	AIME24		AIME25		HMMT25		MBPP+	GPQA _D
	avg@32	pass@32	avg@32	pass@32	avg@32	pass@32		
Qwen3-1.7B	13.44	40.00	9.69	30.00	5.73	23.33	58.24	27.92
w/ OPSA	48.85	80.00	35.31	66.67	23.33	50.00	59.44	32.40
Δ	+35.41	+40.00	+25.62	+36.67	+17.60	+26.67	+1.20	+4.48
	$\uparrow 263.5\%$	$\uparrow 100.0\%$	$\uparrow 264.4\%$	$\uparrow 122.2\%$	$\uparrow 307.2\%$	$\uparrow 114.3\%$	$\uparrow 2.1\%$	$\uparrow 16.0\%$
Qwen3-4B	23.33	56.67	20.52	56.67	13.13	33.33	66.93	38.46
w/ OPSA	62.08	83.33	58.44	83.33	37.40	60.00	68.35	41.29
Δ	+38.75	+26.66	+37.92	+26.66	+24.27	+26.67	+1.42	+2.83
	$\uparrow 166.1\%$	$\uparrow 47.0\%$	$\uparrow 184.8\%$	$\uparrow 47.0\%$	$\uparrow 184.8\%$	$\uparrow 80.0\%$	$\uparrow 2.1\%$	$\uparrow 7.4\%$
Qwen3.5-9B	76.35	93.33	56.04	93.33	44.48	86.67	77.33	70.53
w/ OPSA	87.81	96.67	76.98	96.67	67.40	93.33	79.27	73.70
Δ	+11.46	+3.34	+20.94	+3.34	+22.92	+6.66	+1.94	+3.17
	$\uparrow 15.0\%$	$\uparrow 3.6\%$	$\uparrow 37.4\%$	$\uparrow 3.6\%$	$\uparrow 51.5\%$	$\uparrow 7.7\%$	$\uparrow 2.5\%$	$\uparrow 4.5\%$


Methods	Training	Token Counts	Inference	Avg@32
	Step Time (s)		Time (s)	
Qwen3-1.7B	-	4457	1.78	13.44
+ GRPO	186.2	19108	5.27	33.96
+ OPD	61.2	15286	5.73	32.08
+ OPSA	46.3	23205	6.58	48.85
Qwen3-4B	-	8015	3.31	23.33
+ OPSA	68.6	20972	6.97	62.08
Qwen3.5-9B	-	6847	5.29	76.35
+ OPSA	214.7	9695	6.31	87.81

Methods	AIME24		AIME25		HMMT25		Average	
	avg@32	pass@32	avg@32	pass@32	avg@32	pass@32	avg@32	pass@32
Qwen3-1.7B	13.44	40.00	9.69	30.00	5.73	23.33	9.62	31.11
+ GRPO	33.96	70.00	25.31	50.00	15.10	43.33	24.79	54.44
+ TTRL	19.90	30.00	9.79	30.00	5.73	23.33	11.81	27.78
+ OPD	32.08	73.33	20.52	50.00	13.85	40.00	22.15	54.44
+ OPSD	33.33	73.33	22.50	53.33	14.90	43.33	23.58	56.67
+ OPSA	48.85	80.00	35.31	66.67	23.33	50.00	35.83	65.56
Δ =OPSA-RL _{best}	+14.89	+6.67	+10.00	+13.34	+8.23	+6.67	+11.04	+8.89
Qwen3-1.7B _{Thinking}	46.56	80.00	36.25	73.33	22.92	60.00	35.24	71.11
+ OPSA	52.50	83.33	42.79	73.33	26.85	60.00	40.71	72.22


5-3. 반성적 장문 추론 능력의 발현



(a) Rollout length during training



(b) Reflective token count



(c) Length accuracy relationship


주요 발현 현상

- 1 반성적 단어(Reflective Tokens)의 비중 급증
- 2 추론 길이(Thinking Length)의 자발적 확장


작동 원리

- 분기점(Forking Points)에서의 엔트로피 감지
- 불확실한 경로의 억제 및 경로 재배치
- 반성적 탐색으로의 전환


5-4. ORSA는 모델의 다양성을 훼손하지 않는다



(a) Tree-Style Reasoning Pattern



(b) Pairwise 4-gram Jaccard Distance




(c) Δ Jaccard Distance

기존 문제: 일반 RL(강화학습)은 높은 정답률만 쫓다가 답변이 정형화되어 다양성 (Diversity)이 떨어지는 모드 붕괴(Mode Collapse)가 발생함.

OPSA의 결과: 다양성이 깎이지 않고 유지/향상됨
(Pass@1 ~ Pass@32 성능이 지속 상향).

유지 원인: 모델 전체를 억제하는 대신, 오류 가능성이 높은 하위 20% 불확실한 토큰만 핀포인트로 억제하여 다양한 성공 추론 경로를 보존함.

5-5. 최적 학습 토큰 비율



감사합니다



궁금한 점이 있으시면 언제든지 연락주세요.

[Github](#) JaehoonJung043

[Email](mailto:pooh20030430@gmail.com) pooh20030430@gmail.com

[Tel](tel:010-6371-1256) 010-6371-1256