

ICML 2026

AI-SOTA-STUDY

AlienLM: Alienization of Language for API-Boundary Privacy in Black-Box LLMs

언어 번역 메커니즘을 통한 API 경계에서의 평문 데이터 노출 방지 및 적응 학습 프레임워크

Authors

Jaehee Kim, Pilsung Kang (DSBA Lab, SNU)

Keywords

Black-Box API Privacy · Vocabulary Bijection · Alien Adaptation

Reviewed by:

Dohyeon Lee (Hongik Univ.)

CONTENTS

- 00 PREREQUISITES
- 01 BACKGROUND & MOTIVATIONS
- 03 AilenLM METHOD
- 04 EXPERIMENTS
- 05 LIMITATIONS & CONCLUSIONS

토큰, 토큰나이저, 임베딩

토큰

언어 모델이 텍스트를 이해하고
처리하기 위해 쪼개 놓은
가장 작은 단위의 텍스트 조각

토큰나이저

입력된 문구를 토큰ID로 변환

“오늘 날씨가 좋다”



Tokenizer

[3812, 920, 17, 4421, 35]

임베딩

토큰의 언어적 역할을
숫자 벡터로 표현



텍스트가 모델 입력이 되기까지



블랙박스과 화이트박스

“모델을 사용하는 사람의 시스템 내부에 대한 접근 권한·투명성의 구분”

화이트박스 모델

접근 범위: 구조·가중치·임베딩·그래디언트

수정 가능 범위: 모델 내부와 입출력

보호법 적용: DP 학습, 가중치·임베딩 수정

블랙박스 API

접근 범위: 입력·출력·제공된 API

수정 가능 범위: 주로 API 호출 전후

보호법 적용: 마스킹, 입력 치환, 출력 복원

API 경계의 평문 노출과 기존 접근의 한계



블랙박스 API의 프라이버시 위험

평문 전송: 프롬프트·응답·파인튜닝 데이터가 외부 인프라에서 처리됨

침해 시 즉시 해석 가능: 로그나 트래픽이 유출되면 내용이 그대로 읽힘

정책 의존: 보관 거부 옵션이 있어도 전송·처리 과정의 평문 노출은 남음



기존 기술의 한계점

HE·MPC·TEE: 전용 환경이나 내부 접근이 필요하고 계산 비용이 큼

DP·연합학습: 학습 데이터 보호에는 유용하지만 추론 시 평문 노출은 남음

기존 난독화: 표현력 또는 문맥 보존이 제한되어 모델 성능이 크게 감소

핵심 아이디어: 평문 노출 저감을 언어 번역으로 재해석

"인간은 읽을 수 없지만, LLM은 배워서 사용할 수 있는 외계어"

인공 언어를 정의하고 모델을 적응시켜 API 경계에서 사람이 읽을 수 있는 평문 노출을 줄임



어휘 수준 전단사 사상 (Vocabulary Bijection)

공개 토큰나이저 어휘 사전 기반 1:1 토큰 매핑 수행



클라이언트 번역기 (Client-Side Translator)

전송 전 외계어화, 응답 수신 후 손실 없는 역변환



외계어 적응 학습 (Alien Adaptation Training)

표준 API 파인튜닝만으로 외계어 직관 처리 능력 확보




“피하려면 토마토 발이 짜다”

??



AlienLM 파이프라인 동작 방식



외계어(Alien Language) 구축 알고리즘



Human Opacity

편집 거리를 크게 만들어 원래 표면 문자열과의 유사도를 낮춤

목표: 인간 판독 난이도 증가



LLM Learnability

토큰 간 상대적 의미 관계를 보존해 적응 학습의 부담을 줄임

목표: 의미 관계 보존



Proxy Embedding Optimization

10^5 개 이상의 어휘를 k-NN 후보 축소와 탐욕적 매핑으로 처리

효율성: 128K 어휘 기준 20분 미만

외계어 매핑의 최적화 목적함수

두 목표를 동시에 만족하는 토큰 매핑 선택

$$\sum_{i \in I_\rho} \tilde{d}_{\text{edit}}(s(i), s(f(i))) - \mu d_{\text{sim}}(e_P(i), e_P(f(i))),$$

Opacity / Learnability

편집 거리 최대화

↑ $\tilde{d}_{\text{edit}}$

원래 토큰과 치환 토큰의 표면 문자열을 최대한 다르게

임베딩 유사도 최대화

↓ d_{sim} = ↑ similarity

프록시 임베딩에서 의미적으로 가까운 토큰끼리 연결

균형 계수 μ

μ

가독성 저감과 학습 용이성의 상대적 중요도를 조절

가역 변환과 외계어화 비율 ρ

가역적 변환 수식 (Reversible Transformation)

$$E(x) = \tau^{-1}(f(\tau(x))), \quad D(x') = \tau^{-1}(f^{-1}(\tau(x'))).$$

Lossless Recovery Guaranteed

선택적 외계어화 ($\rho = 0.3$)

93% Oracle

일부 어휘만 치환해 Oracle 성능의 약 93% 유지

전체 외계어화 ($\rho = 1.0$)

82% Oracle

비특수 토큰 전체를 치환하면서 Oracle 성능의 약 82% 유지

시드 분산 (Seed Diversity)

< 2% Overlap

시드별 매핑 중복이 낮아 사용자별 키 분리에 활용 가능

주요 실험 결과: 유틸리티 보존 능력

평균 성능 보존율 (Oracle 대비)

81%+

4개 LLM 백본 및 7개 대표 벤치마크 평가 결과

방법론 (Method)	MMLU	GSM8K	ARC-Challenge
Plaintext Oracle	100%	100%	100%
Random Substitution	24.2%	3.1%	18.5%
AlienLM (Ours)	83.4%	79.8%	82.1%

LLaMA-3 8B, Qwen-2.5 7B·14B, Gemma-2 9B · 7개 벤치마크 평균

위협 모델 및 보안 내성 검증

O1: Passive Observation

수동적 관측 공격

외계어 텍스트만 관측하여 통계적 어휘 및 빈도 분석 수행

복구 성공률 (Recovery Rate)

< 0.01%

O2: Limited Leakage

제한적 데이터 유출

제한된 수의 평문-외계어 쌍(Pair)이 공격자에게 유출된 조건

토큰 매핑 복구율

< 0.22%

O3: Model Access

적응 모델 가중치 접근

적응 학습된 모델 가중치에 직접 접근 가능한 최악의 조건

Top-1 토큰 매핑 복구율

< 0.11%

의의와 실제 배포 조건

🏠 언어 표현과 모델 역량의 분리

LLM이 인간 언어와 다른 표면 문자열에도 적응할 수 있음을 실험으로 보여줌.

📡 즉각적인 배포 실용성

특수 실행 환경이나 서버 수정 없이, 파인튜닝 API가 제공되는 서비스에서 적용 가능

🕒 Sub-millisecond 초저지연

클라이언트 외계어화·역변환은 샘플당 1ms 미만이며 측정상 처리량 차이는 미미함.



한계와 적용 조건

형식적 프라이버시 보장은 아님

실험한 공격에서 복구가 어려웠다는 경험적 결과이며, 암호학이나 차등 프라이버시처럼 수학적으로 증명된 보장은 아니다.

클라이언트 키와 번역기 보호가 전제

매핑 시드나 번역기가 유출되면 외계어를 복원할 수 있다. 메시지 길이 같은 메타데이터도 관찰된다.

안전 정렬 저하와 키 운영 비용

일부 안전 벤치마크 점수가 감소했다. 키를 바꾸면 AAT를 다시 수행해야 하며 다중 테넌트 지원도 제한적이다.

SUMMARY & CONCLUSION

"입력을 외계어로 바꾸고, API LLM을 그 언어에 적응시킨다."

블랙박스 API 경계에서
평문 노출을 줄이는 번역 계층

Oracle 성능 81% 이상 유지
형식적 보장은 향후 과제

Thank You

Questions & Answers