s1: Simple test-time scaling

모델 성능 향상과 Test-Time Scaling을 동시에 달성하는 가장 단순한 방법은 무엇일까?

PAPER REVIEW

EMNLP · 2025

Train-Time에서 Test-Time Scaling으로

Train-Time Scaling

학습 단계에서 더 많은 데이터와 연산량 투입

대규모 자기지도 사전학습 기반

Test-Time Scaling

학습된 모델이 답변을 생성할 때 추가 연산량을 사용하여 성능 향상

o1이 가능성을 제시
R1이 o1급의 추론 성능을 재현했으나,
명확한 Scaling 양상의 공개 재현은 부족

Main Question, Pipeline

“어떻게 가장 단순한 방법으로 강력한 추론 성능과 Test-Time Scaling을 동시에 달성할 수 있을까?”

① s1K 기반 SFT

1,000개 데이터로 모델 추가 학습

② 이어서 Budget Forcing

추론 시점에 토큰 예산과 종료 시점 제어

s1K: 3가지 데이터 선별 기준

59,029 후보

51,581 품질 필터링

24,496 난이도 필터링

384 + 616 → s1K

QUALITY

오류와 형식 문제 제거
학습 가능한 예제 확보

DIFFICULTY

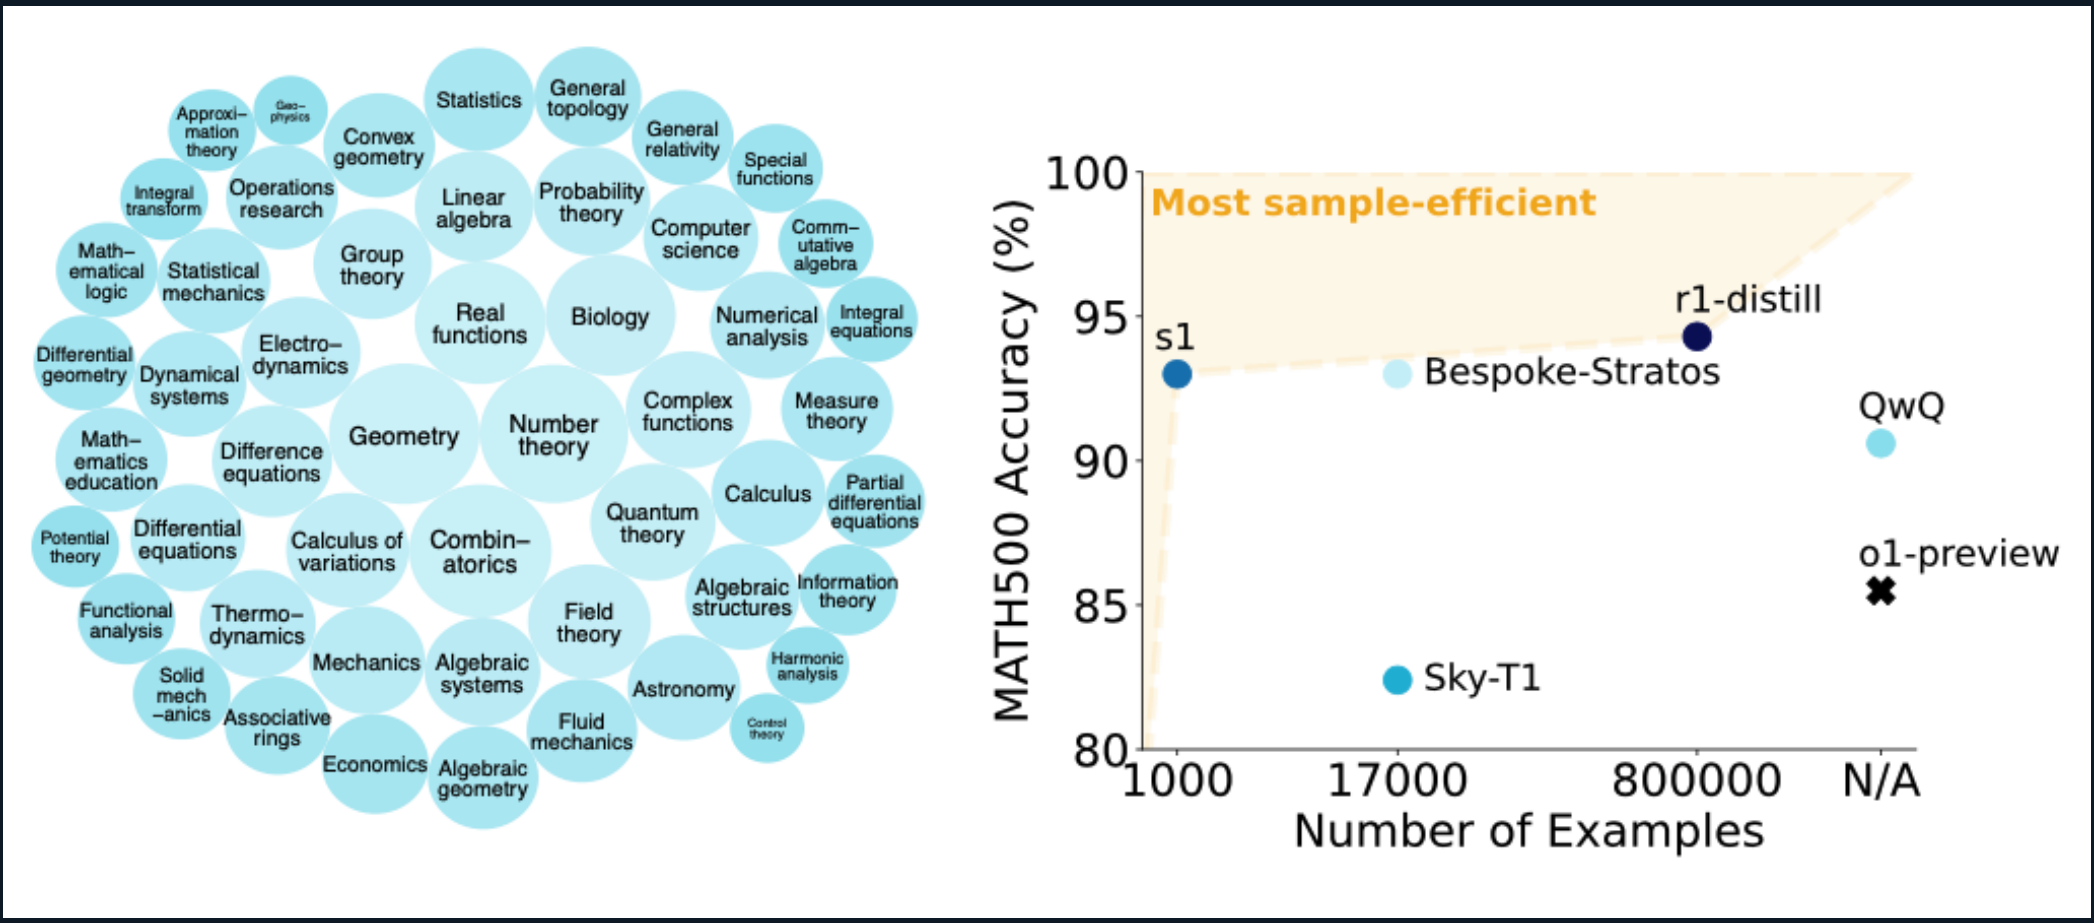
기본 모델이 맞힌 문제 제거
긴 추론 Trace 선호

DIVERSITY

384개는 고품질 출처에서 확보
나머지 616개 분야별 샘플링
특정 유형 편중 방지

중요: 긴 추론 = 무조건 정답이 아니라, 문제 난이도의 간접 지표

Figure 2 : s1K



왼쪽: 다양한 분야의 s1K 1,000개 데이터 | 오른쪽: 학습 예제 수 대비 MATH500 정확도

추론 제어: Budget Forcing

상한 제어 · Stop

추론 토큰이 예산을 초과할 때
종료 구분 토큰을 강제로 추가
→ 답변 생성 단계로 이동

하한 / 연장 · Wait

모델이 추론을 끝내려 할 때
종료를 억제하고 “Wait” 삽입
→ 추가 검토와 자기 수정 유도

모델 파라미터는 그대로: 학습 이후 생성 과정(decoding)에 개입하는 기술

Figure 3 · “Wait”으로 자기 수정 유도

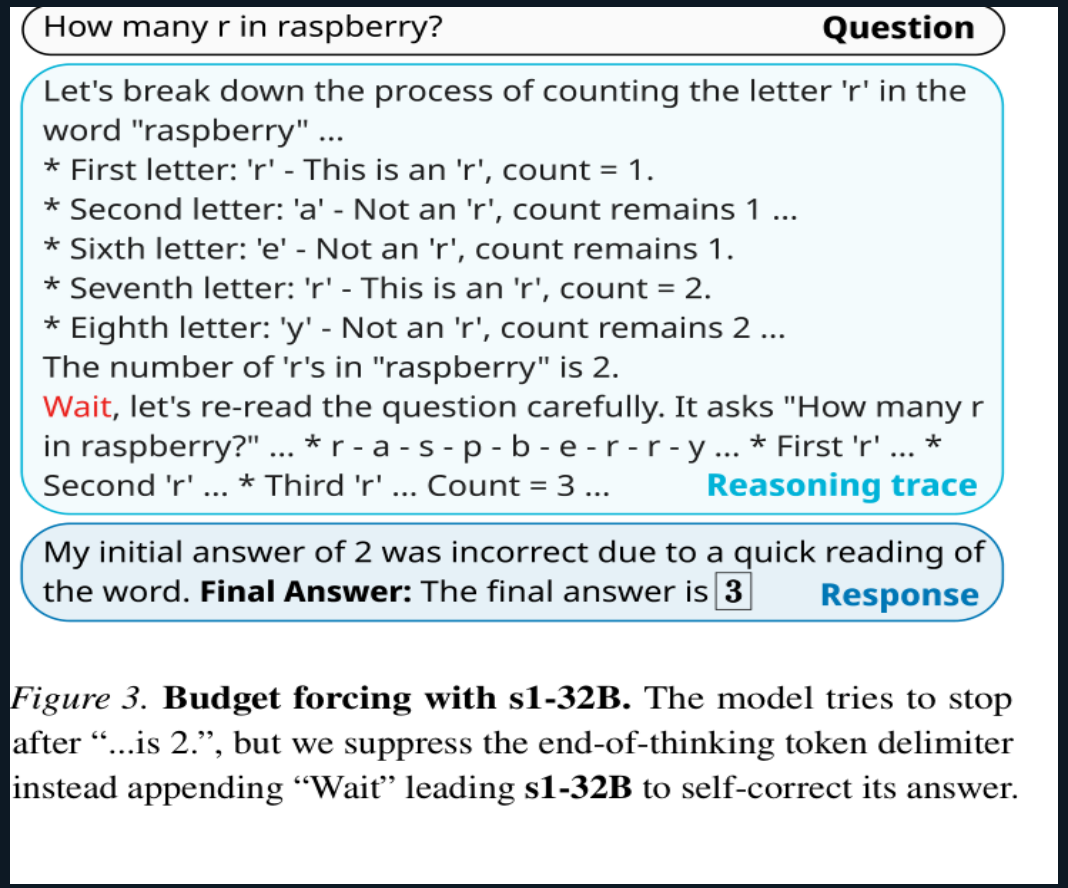


Figure 3. **Budget forcing with s1-32B.** The model tries to stop after “...is 2.”, but we suppress the end-of-thinking token delimiter instead appending “Wait” leading **s1-32B** to self-correct its answer.

1. 모델이 처음에는 raspberry의 r을 2개라고 판단

2. 종료 대신 “Wait”을 삽입해 추론 연장

3. 다시 세어 최종 정답 3개로 수정

길이를 제어하는 다른 방법들

Prompt Control

Token-conditional:
“최대 2,000토큰”

Step-conditional:
“최대 10단계”

Class Control

“짧게 생각해” 또는
“길게 생각해”

정확한 시간·토큰 수
직접 지정은 아님

Rejection Sampling

여러 출력을 생성하고
길이 제약 미충족 시 폐기

정답 여부가 아니라
생성 길이로 선별

평가 지표 3개

CONTROL

설정한 토큰량을
얼마나 정확히 준수하는가
?

0~100% · 높을수록 좋음

SCALING

추론 연산량이 증가할 때
정확도가 얼마나 증가하는
가?

PERFORMANCE

여러 토큰량 설정 중
가장 높은 정확도는?

Scaling = 모든 서로 다른 연산량 쌍 (a,b)에 대한 [f(b)−f(a)] / (b−a)의 평균

Metrics · 평가 지표의 세 가지 수식

01 CONTROL

토큰 예산을 얼마나 준수했는가?

$$\text{Control} = \frac{1}{|\mathcal{A}|} \sum_{a \in \mathcal{A}} \mathbb{I}(a_{\min} \le a \le a_{\max})$$

02 SCALING

연산량 증가 대비 정확도는 얼마나 달라졌는가?

$$\text{Scaling} = \frac{1}{\binom{|\mathcal{A}|}{2}} \sum_{b > a} \frac{f(b) - f(a)}{b - a}$$

03 PERFORMANCE

설정된 예산 중 최고 정확도는?

$$\text{Performance} = \max_{a \in \mathcal{A}} f(a)$$

실험 설계: s1-32B를 어떻게 평가했나?

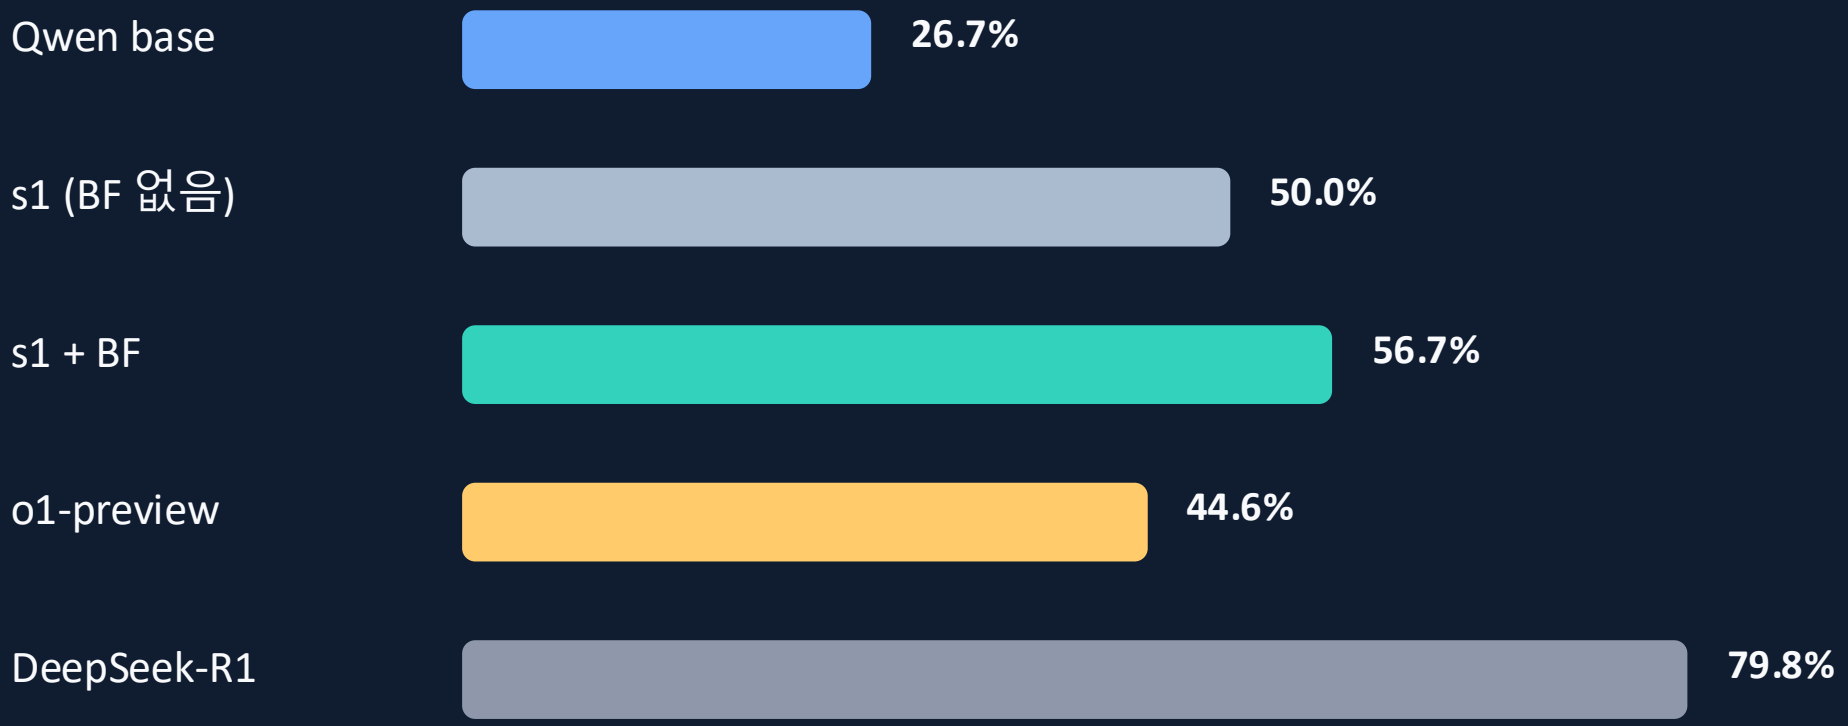
TRAINING

Base: Qwen2.5-32B-Instruct
Data: s1K (1,000문제)
방법: Supervised Fine-Tuning
16× H100, 약 26분

BENCHMARK

AIME24 · 경시 수학 30문제
MATH500 · 수학 500문제
GPQA Diamond · 박사급 과학 198문제
기본 평가: Greedy, pass@1

실험 결과: 정확도



AIME24 정확도 (%) · 논문 Table 1 · 발표 당시의 결과

데이터 Ablation: 1K vs 59K

데이터셋	AIME24	MATH500	GPQA
1K-random	36.7	90.6	52.0
1K-diverse	26.7	91.2	54.6
1K-longest	33.3	90.4	59.6
59K-full	53.3	92.8	58.1
s1K	**50.0**	**93.0**	**57.6**

59K 전체 학습: 394 GPU-hours | s1K: 7 GPU-hours

방법 Ablation: Budget Forcing

방법	Control	Scaling	Performance
Budget Forcing	**100%**	**+15**	**56.7%**
Token Control	40%	−24	40.0%
Step Control	60%	+3	36.7%
Class Control	50%	+25	36.7%
Rejection Sampling	100%	−35	40.0%

BF는 Control 100%와 가장 높은 최고 정확도 달성 · Class Control는 기울기만 더 높음

논문의 한계와 향후 연구

LIMITATIONS

① 일정 길이 이후 성능 향상 정체
② 반복적인 추론 루프 발생
③ Context Window 상한

NEXT STEPS

① Wait 이외 문자열 / 반복 억제
② 강화학습 모델에 BF 적용
③ Parallel Scaling과 결합
(Majority Voting, REBASE)

주의: REBASE는 추가 Reward Model 연산이 필요하며, Figure 7의 토큰 수에는 이 비용이 빠져 있음.

Q & A

Thank you

논문: arxiv.org/abs/2501.19393 | 코드: github.com/simplescaling/s1